

CorroborIA - Détection intelligente des écarts

Concevoir une solution assistée par l'IA capable de comparer les données provenant d'un système source à un système cible, d'appliquer les règles métier qui expliquent certains écarts et de produire un rapport final ne présentant que les erreurs de données réellement à investiguer.

Contexte et problématique

Dans le cadre des échanges de données entre un système maître RH et un système de gestion des horaires et du temps, des extractions des deux systèmes sont comparées afin de vérifier que les informations transférées dans le système cible correspondent bien aux données attendues. Une corroboration existe déjà et permet d'identifier, champ par champ, si les valeurs sont identiques ou différentes.

Cependant, une différence entre les deux sources ne signifie pas nécessairement qu'il y a une erreur. Certaines situations sont légitimes et nécessitent aujourd'hui des validations complémentaires avec des règles métiers pour confirmer que le résultat est acceptable. Ces vérifications manuelles demandent du temps, nécessitent une connaissance du système et peuvent entraîner des interprétations variables.

Le défi consiste donc à aller au-delà d'une simple comparaison « identique / différent » afin d'automatiser l'analyse des écarts et de concentrer l'attention humaine sur les anomalies réellement pertinentes.

Comment utiliser l'IA, combinée aux règles de corroboration existantes, pour distinguer automatiquement un écart justifié d'une véritable erreur de données entre Système A - RH et Système B - Temps, expliquer la décision prise et produire un rapport de corroboration fiable et exploitable?

Objectifs du défi

Objectif principal

Développer un prototype de corroboration intelligente qui compare les données entre le système A - RH et le système B - Temps, en appliquant les règles métier pertinentes. Classer chaque écart avec une justification compréhensible.

Objectifs spécifiques

- Automatiser la comparaison des champs entre les deux sources et normaliser les données lorsque nécessaire (formats, valeurs vides, dates, libellés, structures répétitives, etc.).
- Intégrer les règles métier et les validations complémentaires afin de reconnaître les écarts acceptables sans intervention manuelle.
- Utiliser une approche d'IA pertinente pour aider à classer, expliquer ou prioriser les écarts qui ne peuvent pas être résolus par une simple règle déterministe.
- Produire un rapport final clair présentant les vraies anomalies, la règle appliquée et la justification du verdict.

Données et ressources

Jeux de données fournis par Loto-Québec à partir d'extractions du système A - RH et du système B - Temps. Les données utilisées pour l'événement sont anonymisées selon les exigences de confidentialité.

Les fichiers fournis sont des extractions anonymisées des deux systèmes, accompagnées du mapping et des règles métier.

- Extraction de la source (système A - RH) - format CSV/Excel
- Extraction complémentaire du détail du poste et des motifs des situations d'emploi afin d'effectuer des jointures avec l'extraction des employés (Système A - RH)
- Extraction de la cible (système B - Temps) - format CSV/Excel
- Fichier de mapping illustrant les correspondances entre les champs des deux sources
- Ensemble de règles de validation métier
- Glossaire des différents libellés

Contraintes particulières

- Les fichiers sources doivent être considérés en lecture seule : la solution ne doit pas modifier les données d'origine.
- La solution doit être explicable : un verdict sans justification ne sera pas considéré suffisant.
- Les règles métier fournies doivent être respectées et traçables dans le résultat.
- La solution doit pouvoir distinguer ce qui relève d'une règle déterministe de ce qui relève d'une analyse assistée par l'IA.
- Prendre note que tous les champs dans l'extraction ne sont pas nécessairement à corroborer. Se fier uniquement aux fichiers de mapping.

Tâche demandée aux participants

Les participants devront :

- Charger et comprendre les données provenant des deux sources à l'aide du mapping fourni.
- Construire un moteur de corroboration qui identifie les écarts, applique les règles métier et exécute les validations complémentaires nécessaires.
- Intégrer une composante d'IA pour améliorer l'analyse des cas ambigus, classifier ou prioriser les écarts et générer une justification exploitable.
- Générer un rapport final permettant à une équipe fonctionnelle de voir rapidement les vraies erreurs, les écarts justifiés et les raisons ayant mené au verdict.

Technologies

Technologies recommandées :

Python, pandas ou Polars, Jupyter, scikit-learn et/ou un modèle de langage (LLM) ou autre approche d'IA jugée pertinente.

Technologies obligatoires, s'il y en a :

Aucune technologie d'IA précise n'est imposée.

Technologies interdites ou restrictions, s'il y en a :

Aucune donnée confidentielle ou personnelle ne doit être transmise vers un service externe non autorisé. Les équipes doivent utiliser uniquement les données et environnements approuvés dans le cadre du défi.

6. Livrables attendus

À la fin du défi, les équipes devront remettre :

- Code source : solution exécutable permettant de reproduire l'analyse de corroboration sur les fichiers fournis.
- Notebook Jupyter (.ipynb) : facultatif, mais recommandé pour expliquer l'exploration des données, les choix d'approche et les résultats.
- Modèle entraîné : si applicable, fournir le modèle ou la procédure permettant de le reproduire.
- Application / prototype : interface simple ou démonstrateur permettant de charger les fichiers, lancer la corroboration et consulter les résultats.
- README / documentation : expliquer l'architecture, les règles prises en charge, l'utilisation de l'IA, les hypothèses, les limites et les étapes d'exécution.
- Démonstration : présentation courte montrant au minimum un cas conforme, un écart justifié automatiquement et une vraie anomalie détectée.

- Autre : rapport de corroboration exportable (CSV, Excel ou format équivalent) avec le verdict, la justification et les informations utiles à l'investigation.

7. Critères d'évaluation

Critère	Description	Points
Exactitude de la corroboration	Capacité à identifier correctement les cas conformes, les écarts justifiés et les anomalies réelles sur le jeu de test.	35
Pertinence de l'utilisation de l'IA	L'IA apporte une valeur réelle dans l'analyse, la classification, la priorisation ou l'explication des écarts, au-delà de règles statiques.	25
Explicabilité et traçabilité	Chaque verdict peut être compris et relié aux données et/ou à la règle ayant conduit à la décision.	20
Qualité technique et utilisabilité	Qualité du code, robustesse, documentation et facilité d'utilisation du prototype ou du rapport final.	20
Total		100

8. Bonus (facultatif)

Idées de bonus :

- Ajouter un mécanisme de niveau de confiance ou de score de priorité afin d'ordonner les anomalies à investiguer.
- Permettre à un expert fonctionnel de corriger un verdict et d'utiliser ce retour pour améliorer les analyses futures ou enrichir automatiquement la base de règles.
- Créer une interface permettant d'expliquer pourquoi un écart est considéré comme acceptable ou problématique et d'afficher les données ayant servi à la décision.

9. Conseils et ressources (facultatif)

Conseils :

- Commencez par séparer clairement trois niveaux : comparaison brute des valeurs, application des règles métier, puis analyse des cas qui demeurent ambigus.
- Ne cherchez pas nécessairement à remplacer toutes les règles par un modèle d'IA : une approche hybride règles + IA sera souvent plus fiable, plus explicable et plus facile à valider.
- Pensez comme la personne qui devra investiguer une erreur : quelles informations doit-elle voir pour comprendre rapidement le verdict et reproduire la validation ?

Documentation / ressources :

- Dictionnaire de données et mapping Système A – RH ↔ Système B – Temps fourni avec le défi.
- Catalogue des règles métier